Введение в искусственный интеллект. Современное компьютерное зрение

Тема: Несверточные слои

Бабин Д.Н., Иванов И.Е.

кафедра Математической Теории Интеллектуальных Систем

03 марта 2026 г.

План лекции

1. Субдискретизация
2. Нелинейность
3. Полносвязный и Softmax слои
4. Дропаут
5. Пакетная нормализация

Визуализация работы сверточной сети[1]

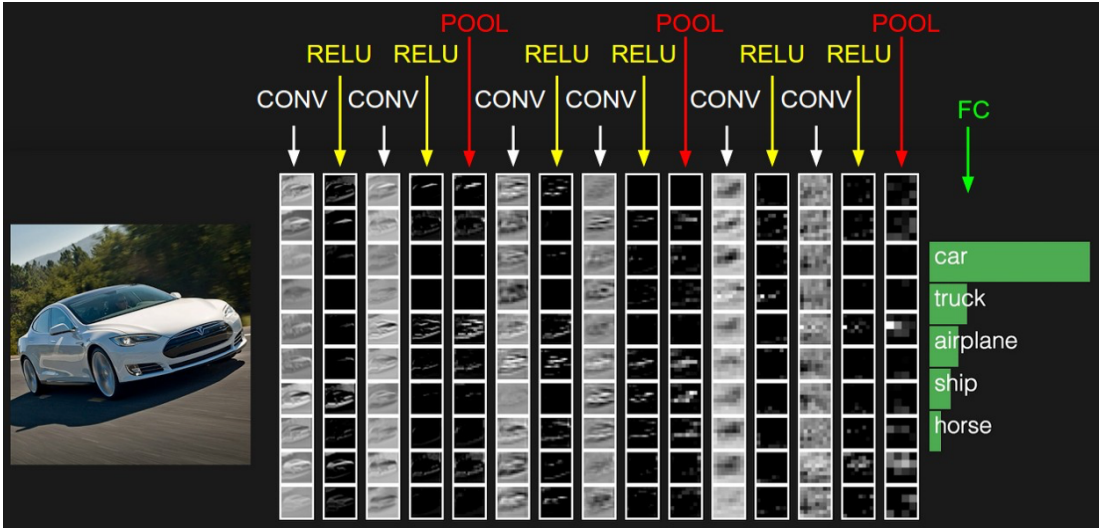

[1] https://cs.stanford.edu/people/karpathy/convnetjs/demo/cifar10.html

Основные типы слоев в СНС

С прошлой лекции:

Входной слой INPUT

Необработанные пиксельные значения входной картинки. Это — первый слой в СНС.

Основные типы слоев в СНС

С прошлой лекции:

Входной слой INPUT

Необработанные пиксельные значения входной картинки. Это — первый слой в СНС.

Сверточный слой CONV

Скалярное произведение между элементами фильтра (также называемого **ядром** свертки) и ограниченой областью (обычно гораздо меньше всей площади $H \times W$) входного слоя, с которой имеются связи, с помощью скользящего окна (слева направо сверху вниз).

Основные типы слоев в СНС

Сегодня:

Нелинейность ReLU

Нелинейность вида $ReLU(x) = \max(0, x)$, применяемая ко всем нейронам слоя поточечно.

Основные типы слоев в СНС

Сегодня:

Нелинейность ReLU

Нелинейность вида $ReLU(x) = \max(0, x)$, применяемая ко всем нейронам слоя поточечно.

Слой субдискретизации POOL

Уменьшение размерности по пространственным измерениям w, h. Могут использоваться разные подходы: усреднение, взятие максимума по подобласти и т.п.

Основные типы слоев в СНС

Сегодня:

Нелинейность ReLU

Нелинейность вида $ReLU(x) = \max(0, x)$, применяемая ко всем нейронам слоя поточечно.

Слой субдискретизации POOL

Уменьшение размерности по пространственным измерениям w, h. Могут использоваться разные подходы: усреднение, взятие максимума по подобласти и т.п.

Полносвязный слой FC (Fully connected)

Матричное умножение — в данном случае каждый нейрон выходного слоя связан со всеми нейронами входного слоя (в отличие от сверточного слоя).

Субдискретидация

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	

Субдискретидация

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	

Слой субдискретизации решает две проблемы:

Субдискретидация

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	

Слой субдискретизации решает две проблемы:

- Снижает пространственную размерность

Субдискретидация

1	3	2	9
7	4	1	5
8	5	2	3
4	2	1	4

7	9
8	

Слой субдискретизации решает две проблемы:

- Снижает пространственную размерность
- Помогает не переобучаться

Параметры слоя субдискретизации

Размер фильтра

Пространственная размерность области (по горизонтали и вертикали), внутри которой применяется функция уменьшения размерности (max, avg).

Параметры слоя субдискретизации

Размер фильтра

Пространственная размерность области (по горизонтали и вертикали), внутри которой применяется функция уменьшения размерности (max, avg).

Шаг (stride)

Количество элементов по горизонтали или вертикали, на которое перемещается фильтр для получения результирующей карты признаков.

Иллюстрация уменьшения размерности

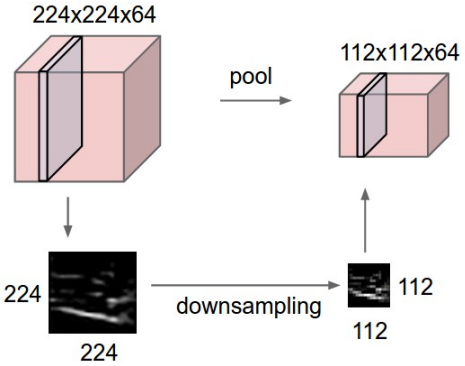

Иллюстрация уменьшения размерности

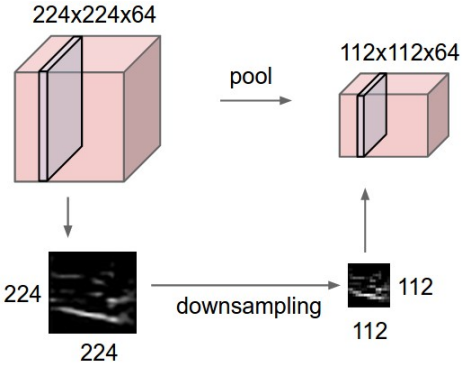

Активация

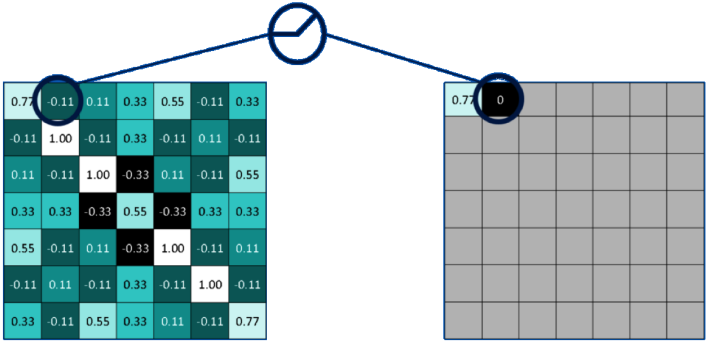
0.77 -0.11 0.11 0.33 0.55 -0.11 0.33
-0.11 1.00 -0.11 0.33 -0.11 0.11 -0.11
0.11 -0.11 1.00 -0.33 0.11 -0.11 0.55
0.33 0.33 -0.33 0.55 -0.33 0.33 0.33
0.55 -0.11 0.11 -0.33 1.00 -0.11 0.11
-0.11 0.11 -0.11 0.33 -0.11 1.00 -0.11
0.33 -0.11 0.55 0.33 0.11 -0.11 0.77
0.77 0

Активация

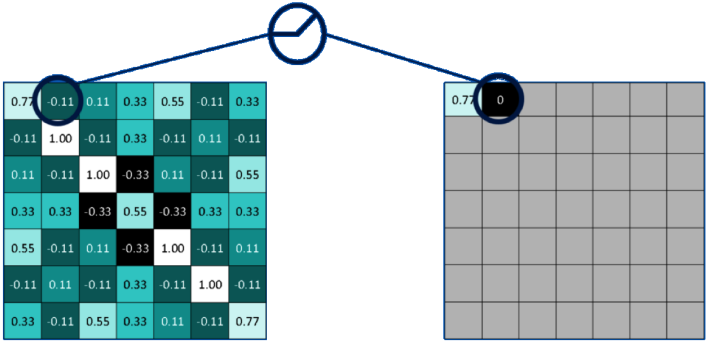

- Применение нелинейной функции (например, $ReLU(x) = \max(0, x)$)

Активация

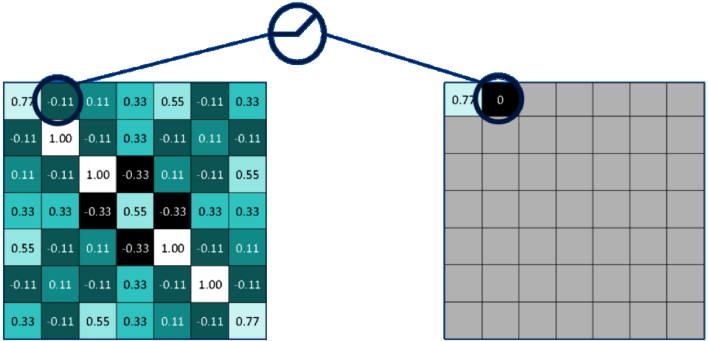

- Применение нелинейной функции (например, $ReLU(x) = \max(0, x)$)
- Цель: выделение наиболее значимой информации

Слой нелинейности

- Также называется активацией

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$
- Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$
- Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$
- Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$
- Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$
- Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$
- ReLU с утечкой (Leaky ReLU) $LReLU(x) = (x < 0) * \alpha x + (x \geq 0) * x$

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$
- Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$
- Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$
- ReLU с утечкой (Leaky ReLU) $LReLU(x) = (x < 0) * \alpha x + (x \geq 0) * x$
- $Maxout(x) = \max(a_1 x + b_1, a_2 x + b_2)$

Слой нелинейности

- Также называется активацией
- Нужен для увеличения эффективной глубины СНС.
- Применяется поэлементно для нейронов всего слоя.
- Обычно не имеет обучаемых параметров (за редким исключением, например, PReLU)

Примеры активаций

- Rectified Linear Unit $ReLU(x) = \max(0, x)$
- Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$
- Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$
- ReLU с утечкой (Leaky ReLU) $LReLU(x) = (x < 0) * \alpha x + (x \geq 0) * x$
- $Maxout(x) = \max(a_1 x + b_1, a_2 x + b_2)$
- Экспоненциальный Linear Unit $ELU(x) = (x < 0) * \alpha(\exp(x) - 1) + (x \geq 0) * x$

Иллюстрация активаций

Activation Functions

Sigmoid

$\sigma(x) = \frac{1}{1+e^{-x}}$

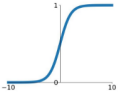

tanh

$\tanh(x)$

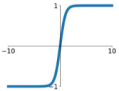

ReLU

$\max(0, x)$

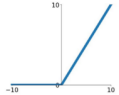

Leaky ReLU

$\max(0.1x, x)$

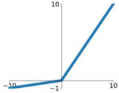

Maxout

$\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

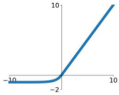

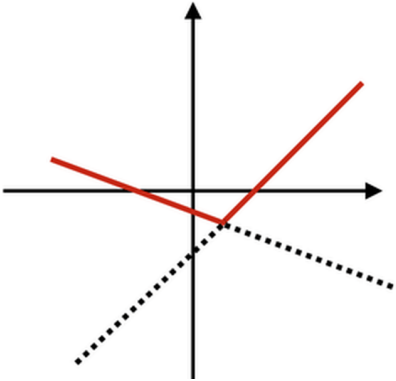

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов
2. Для этого сначала вычисляют N т.н. *логитов* l_i — скалярных значений из $\mathbb{R}$

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов
2. Для этого сначала вычисляют N т.н. *логитов* l_i — скалярных значений из $\mathbb{R}$
3. При этом на выходе последней операции СНС (например, свертки) может оказаться тензор X' произвольного размера $M = d * w * h$, который может быть преобразован для упрощения вычислений в вектор X размера $M \times 1$

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов
2. Для этого сначала вычисляют N т.н. *логитов* l_i — скалярных значений из $\mathbb{R}$
3. При этом на выходе последней операции СНС (например, свертки) может оказаться тензор X' произвольного размера $M = d * w * h$, который может быть преобразован для упрощения вычислений в вектор X размера $M \times 1$
4. Как раз для преобразования M входов в N выходов-логитов и применяется полносвязный слой, или умножение на матрицу A размера $N \times M$: $Y = A * X, Y_i = l_i$

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов
2. Для этого сначала вычисляют N т.н. *логитов* l_i — скалярных значений из $\mathbb{R}$
3. При этом на выходе последней операции СНС (например, свертки) может оказаться тензор X' произвольного размера $M = d * w * h$, который может быть преобразован для упрощения вычислений в вектор X размера $M \times 1$
4. Как раз для преобразования M входов в N выходов-логитов и применяется полносвязный слой, или умножение на матрицу A размера $N \times M$: $Y = A * X, Y_i = l_i$
5. Иногда к результату умножения на матрицу добавляют одномерный тензор сдвига b^k длины N

Полносвязный слой

1. Для классификации на N классов обычно определяют *вероятность* p_i принадлежности к каждому из классов
2. Для этого сначала вычисляют N т.н. *логитов* l_i — скалярных значений из $\mathbb{R}$
3. При этом на выходе последней операции СНС (например, свертки) может оказаться тензор X' произвольного размера $M = d * w * h$, который может быть преобразован для упрощения вычислений в вектор X размера $M \times 1$
4. Как раз для преобразования M входов в N выходов-логитов и применяется полносвязный слой, или умножение на матрицу A размера $N \times M$: $Y = A * X, Y_i = l_i$
5. Иногда к результату умножения на матрицу добавляют одномерный тензор сдвига b^k длины N

Замечание. Обычно полносвязные слои — самые большие по объему и не очень быстрые, поэтому нужно стараться их избегать (average pooling) либо оптимизировать

Слой Softmax

1. Операция Softmax — это обобщение сигмоиды на случай N входов:

$$Softmax(Y)_i = \frac{e^{l_i}}{\sum_{k=1}^{N} e^{l_k}} = p_i$$

Слой Softmax

1. Операция Softmax — это обобщение сигмоиды на случай N входов:

$$Softmax(Y)_i = \frac{e^{l_i}}{\sum_{k=1}^{N} e^{l_k}} = p_i$$

2. Теперь p_i — корректный вектор вероятностей:

$$\sum_{k=1}^{N} p_k = 1, \quad 0 \leq p_i \leq 1 \quad \forall i = 1 \ldots N$$

Шаблоны построения СНС

Шаблон глубокой СНС

INPUT→[[CONV→RELU]*N→POOL?]*M→[FC→RELU]*K→Softmax

Шаблоны построения СНС

Шаблон глубокой СНС

INPUT→[[CONV→RELU]*N→POOL?]*M→[FC→RELU]*K→Softmax

Замечание. Современные СНС зачастую имеют немного более сложную структуру

1. Сети типа ResNet имеют т.н. остаточные (residual) связи

Шаблоны построения СНС

Шаблон глубокой СНС

INPUT→[[CONV→RELU]*N→POOL?]*M→[FC→RELU]*K→Softmax

Замечание. Современные СНС зачастую имеют немного более сложную структуру

1. Сети типа ResNet имеют т.н. остаточные (residual) связи
2. Сети типа Inception предлагают конкатенацию слоев + разделение одной 2D свертки на две 1D свертки

Шаблоны построения СНС

Шаблон глубокой СНС

INPUT→[[CONV→RELU]*N→POOL?]*M→[FC→RELU]*K→Softmax

Замечание. Современные СНС зачастую имеют немного более сложную структуру

1. Сети типа ResNet имеют т.н. остаточные (residual) связи
2. Сети типа Inception предлагают конкатенацию слоев + разделение одной 2D свертки на две 1D свертки
3. Слой BatchNormalization выполняет послойную нормализацию

Шаблоны построения СНС

Шаблон глубокой СНС

INPUT→[[CONV→RELU]*N→POOL?]*M→[FC→RELU]*K→Softmax

Замечание. Современные СНС зачастую имеют немного более сложную структуру

1. Сети типа ResNet имеют т.н. остаточные (residual) связи
2. Сети типа Inception предлагают конкатенацию слоев + разделение одной 2D свертки на две 1D свертки
3. Слой BatchNormalization выполняет послойную нормализацию
4. DropOut борется с переобучением

Откуда берутся размерности ≥ 4

Размерность 4

Обычно это размерность т.н. пакета (batch) входных данных, над которыми все операции выполняются совершенно идентично и параллельно (в рамках используемой архитектуры). Например, размер пакета из 32 входных картинок

Откуда берутся размерности ≥ 4

Размерность 4

Обычно это размерность т.н. пакета (batch) входных данных, над которыми все операции выполняются совершенно идентично и параллельно (в рамках используемой архитектуры). Например, размер пакета из 32 входных картинок

Размерность 5

Дополнительная размерность необходима для обработки видео и задает количество кадров, при этом она будет четвертой размерностью, а на пятую сдвинется размер пакета (он всегда либо первый, либо последний — в зависимости от реализации).

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$
- Это можно сделать, зануляя “выключенные” нейроны

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$
- Это можно сделать, зануляя “выключенные” нейроны
- На тесте нейроны не выключаются; при этом выход нейрона умножается на p

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$
- Это можно сделать, зануляя “выключенные” нейроны
- На тесте нейроны не выключаются; при этом выход нейрона умножается на p
  - Матожидание выхода нейрона при обучении $px + (1 - p)0 = px$ (т.к. мы либо пропускаем нейрон без изменений, либо зануляем)

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$
- Это можно сделать, зануляя “выключенные” нейроны
- На тесте нейроны не выключаются; при этом выход нейрона умножается на p
  - Матожидание выхода нейрона при обучении $px + (1 - p)0 = px$ (т.к. мы либо пропускаем нейрон без изменений, либо зануляем)
  - Поэтому при тестировании, когда все нейроны включены, их выходы нужно шкалировать для такого же матожидания

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Дропаут[2] (выброс)

- Для уменьшения переобучения, во время обучения нейроны “выключают” с вероятностью $0 \leq 1 - p \leq 1$
- Это можно сделать, зануляя “выключенные” нейроны
- На тесте нейроны не выключаются; при этом выход нейрона умножается на p
  - Матожидание выхода нейрона при обучении $px + (1 - p)0 = px$ (т.к. мы либо пропускаем нейрон без изменений, либо зануляем)
  - Поэтому при тестировании, когда все нейроны включены, их выходы нужно шкалировать для такого же матожидания
- Либо при обучении делим выход на p: тогда на тесте ничего домножать не надо

[2] Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”, 2014

Схема дропаута

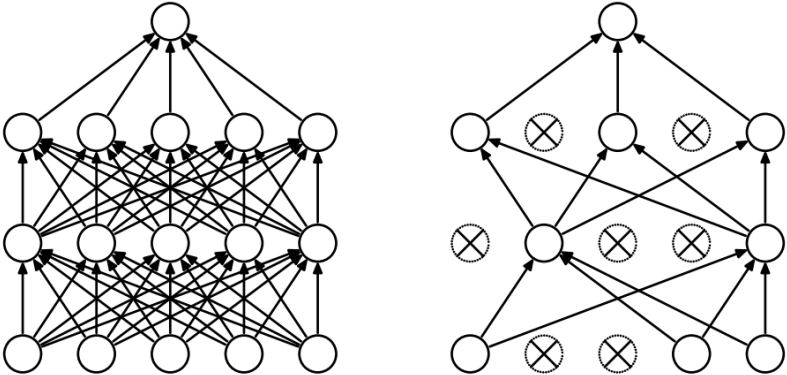

(a) Standard Neural Net (b) After applying dropout.

Внутренний ковариативный сдвиг

Проблема

[3] LeCun Y. A. et al. “Efficient backprop”. 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения
- Более глубокая нейросеть $\Rightarrow$ больший сдвиг

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения
- Более глубокая нейросеть $\Rightarrow$ больший сдвиг

Очевидные пути решения для глубоких нейросетей (следующая лекция)

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения
- Более глубокая нейросеть $\Rightarrow$ больший сдвиг

Очевидные пути решения для глубоких нейросетей (следующая лекция)

- Очень аккуратная инициализация параметров нейросети

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения
- Более глубокая нейросеть $\Rightarrow$ больший сдвиг

Очевидные пути решения для глубоких нейросетей (следующая лекция)

- Очень аккуратная инициализация параметров нейросети
- Маленький коэффициент скорости обучения (и, как следствие, очень медленное обучение)

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Внутренний ковариативный сдвиг

Проблема

- Внутренний ковариативный сдвиг (Internal Covariate Shift, ICS) — изменение распределения значений нейронов вследствие изменения параметров нейросети во время обучения
- Более глубокая нейросеть $\Rightarrow$ больший сдвиг

Очевидные пути решения для глубоких нейросетей (следующая лекция)

- Очень аккуратная инициализация параметров нейросети
- Маленький коэффициент скорости обучения (и, как следствие, очень медленное обучение)
- Нормализация входа[3] (помогает слабо)

[3] LeCun Y. A. et al. "Efficient backprop". 1998

Пакетная нормализация[4]

Решение

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)
- Дальше для обучения параметров нейросети будут подаваться уже нормализованные значения (и т.о. уменьшаем ICS)

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)
- Дальше для обучения параметров нейросети будут подаваться уже нормализованные значения (и т.о. уменьшаем ICS)

Преимущества BN

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)
- Дальше для обучения параметров нейросети будут подаваться уже нормализованные значения (и т.о. уменьшаем ICS)

Преимущества BN

- За счет большего learning rate скорость обучения возрастает в разы

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)
- Дальше для обучения параметров нейросети будут подаваться уже нормализованные значения (и т.о. уменьшаем ICS)

Преимущества BN

- За счет большего learning rate скорость обучения возрастает в разы
- Не так чувствительна к инициализации

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Пакетная нормализация[4]

Решение

- **Нормализация по пакету** (Batch Normalization, BN) — та самая 4 размерность
- Можно нормализовать каждый слой (а не только вход)
- Нужно нормализовать на каждом пакете данных (mini-batch)
- Дальше для обучения параметров нейросети будут подаваться уже нормализованные значения (и т.о. уменьшаем ICS)

Преимущества BN

- За счет большего learning rate скорость обучения возрастает в разы
- Не так чувствительна к инициализации
- Не нужен дропаут

[4] Ioffe S., Szegedy C. "Batch normalization: Accelerating deep network training by reducing internal covariate shift". 2015

Когда и где применять BN

Когда

Когда и где применять BN

Когда

- В глубоких нейросетях

Когда и где применять BN

Когда

- В глубоких нейросетях
- Нужно ускорить скорость обучения

Когда и где применять BN

Когда

- В глубоких нейросетях
- Нужно ускорить скорость обучения

Где

Когда и где применять BN

Когда

- В глубоких нейросетях
- Нужно ускорить скорость обучения

Где

- **После** операции свертки или других матричных операций

Когда и где применять BN

Когда

- В глубоких нейросетях
- Нужно ускорить скорость обучения

Где

- **После** операции свертки или других матричных операций
- **До** применения функции активации (до ReLU) — т.к. функция активации сама по себе сильно меняет распределение

Когда и где применять BN

Когда

- В глубоких нейросетях
- Нужно ускорить скорость обучения

Где

- **После** операции свертки или других матричных операций
- **До** применения функции активации (до ReLU) — т.к. функция активации сама по себе сильно меняет распределение
- Тем не менее, есть свидетельства, что порой можно применить BN и после активации (хотя и не всегда это работает)

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Обучение

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Обучение

- Подсчитываем μ_B и σ_B на пакете B

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Обучение

- Подсчитываем μ_B и σ_B на пакете B
- Обновляем глобальные значения (соотв. всему обучающему множеству) μ_{avg} и σ_{avg}

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Обучение

- Подсчитываем μ_B и σ_B на пакете B
- Обновляем глобальные значения (соотв. всему обучающему множеству) μ_{avg} и σ_{avg}

Тестирование

Режимы работы BN

BN работает по-разному во время тестирования (т.н. inference mode) и во время обучения

Обучение

- Подсчитываем μ_B и σ_B на пакете B
- Обновляем глобальные значения (соотв. всему обучающему множеству) μ_{avg} и σ_{avg}

Тестирование

- Используем значения μ_{avg} и σ_{avg} вне зависимости от μ_B и σ_B на текущем пакете

BN: статистика на пакете

- Предположим, что мы используем пакет размера T

BN: статистика на пакете

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где

BN: статистика на пакете

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

BN: статистика на пакете

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика на пакете

BN: статистика на пакете

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика на пакете

- $\mu_B^m = \frac{1}{HWT} \sum_t \sum_{i,j} X_{ij}^{mt}$

BN: статистика на пакете

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика на пакете

- $\mu_B^m = \frac{1}{HWT} \sum_t \sum_{i,j} X_{ij}^{mt}$
- $\sigma_B^{2m} = \frac{1}{HWT} \sum_t \sum_{i,j} (X_{ij}^{mt} - \mu_B^m)^2$

BN: режим обучения

Гиперпараметры

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

- $\mu^m_{avg,k} = \alpha\mu^m_{avg,k-1} + (1-\alpha)\mu^m_B$ (инициализация $\mu^m_{avg,0} = 0$)

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

- $\mu^m_{avg,k} = \alpha\mu^m_{avg,k-1} + (1-\alpha)\mu^m_B$ (инициализация $\mu^m_{avg,0} = 0$)
- $\sigma^{2m}_{avg,k} = \alpha\sigma^{2m}_{avg,k-1} + (1-\alpha)\sigma^{2m}_B$ (инициализация $\sigma^{2m}_{avg,0} = 1$)

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

- $\mu^m_{avg,k} = \alpha\mu^m_{avg,k-1} + (1-\alpha)\mu^m_B$ (инициализация $\mu^m_{avg,0} = 0$)
- $\sigma^{2m}_{avg,k} = \alpha\sigma^{2m}_{avg,k-1} + (1-\alpha)\sigma^{2m}_B$ (инициализация $\sigma^{2m}_{avg,0} = 1$)
- Выход нормализованного слоя: $Y^{mt}_{ij} = \gamma^m \frac{X^{mt}_{ij} - \mu^m_B}{\sqrt{\sigma^{2m}_B + \epsilon}} + \beta^m$

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

- $\mu^m_{avg,k} = \alpha\mu^m_{avg,k-1} + (1-\alpha)\mu^m_B$ (инициализация $\mu^m_{avg,0} = 0$)
- $\sigma^{2m}_{avg,k} = \alpha\sigma^{2m}_{avg,k-1} + (1-\alpha)\sigma^{2m}_B$ (инициализация $\sigma^{2m}_{avg,0} = 1$)
- Выход нормализованного слоя: $Y^{mt}_{ij} = \gamma^m \frac{X^{mt}_{ij} - \mu^m_B}{\sqrt{\sigma^{2m}_B + \epsilon}} + \beta^m$
- Параметры γ^m (масштаб, scale) и β^m (сдвиг, shift) — обучаемые

BN: режим обучения

Гиперпараметры

- $\alpha \in [0, 1]$: параметр сглаживания для обновления глобальных параметров
- $\epsilon > 0$ — регуляризатор (маленькое число)

Шаг обучения k

- $\mu^m_{avg,k} = \alpha\mu^m_{avg,k-1} + (1-\alpha)\mu^m_B$ (инициализация $\mu^m_{avg,0} = 0$)
- $\sigma^{2m}_{avg,k} = \alpha\sigma^{2m}_{avg,k-1} + (1-\alpha)\sigma^{2m}_B$ (инициализация $\sigma^{2m}_{avg,0} = 1$)
- Выход нормализованного слоя: $Y^{mt}_{ij} = \gamma^m \frac{X^{mt}_{ij} - \mu^m_B}{\sqrt{\sigma^{2m}_B + \epsilon}} + \beta^m$
- Параметры γ^m (масштаб, scale) и β^m (сдвиг, shift) — обучаемые

Замечание. В случае $\gamma^m = \sqrt{\sigma^{2m}_B + \epsilon}, \beta^m = \mu^m_B$ получим $Y^{mt}_{ij} = X^{mt}_{ij}$ и BN в принципе может обучиться ничего не делать (ничего не портить).

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}
4. Выход нормализованного слоя: $Y_{ij}^{mt} = \gamma^m \frac{X_{ij}^{mt} - \mu_{avg}^m}{\sqrt{\sigma_{avg}^{2m} + \epsilon}} + \beta^m$

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}
4. Выход нормализованного слоя: $Y_{ij}^{mt} = \gamma^m \frac{X_{ij}^{mt} - \mu_{avg}^m}{\sqrt{\sigma_{avg}^{2m} + \epsilon}} + \beta^m$

Число параметров для BN

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}
4. Выход нормализованного слоя: $Y_{ij}^{mt} = \gamma^m \frac{X_{ij}^{mt} - \mu_{avg}^m}{\sqrt{\sigma_{avg}^{2m} + \epsilon}} + \beta^m$

Число параметров для BN

- Для каждой карты признаков нужно хранить 4 числа: 2 — глобальные статистики, и 2 — параметры сдвига и масштаба

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}
4. Выход нормализованного слоя: $Y_{ij}^{mt} = \gamma^m \frac{X_{ij}^{mt} - \mu_{avg}^m}{\sqrt{\sigma_{avg}^{2m} + \epsilon}} + \beta^m$

Число параметров для BN

- Для каждой карты признаков нужно хранить 4 числа: 2 — глобальные статистики, и 2 — параметры сдвига и масштаба
- Если L слоев по M карт каждый, то число BN параметров составляет $N_{BN} = 4LM$

BN: режим теста

1. Используем уже обученные параметры масштаба γ^m и сдвига β^m
2. Несмотря на то, что в тесте данные тоже могут подаваться пакетами, не обращаем внимание на статистику пакета μ_B^m и σ_B^{2m}
3. Не обновляем глобальные параметры μ_{avg}^m и σ_{avg}^{2m}
4. Выход нормализованного слоя: $Y_{ij}^{mt} = \gamma^m \frac{X_{ij}^{mt} - \mu_{avg}^m}{\sqrt{\sigma_{avg}^{2m} + \epsilon}} + \beta^m$

Число параметров для BN

- Для каждой карты признаков нужно хранить 4 числа: 2 — глобальные статистики, и 2 — параметры сдвига и масштаба
- Если L слоев по M карт каждый, то число BN параметров составляет $N_{BN} = 4LM$
- $N_{BN} \ll N_{CONV}$

BN: эффект

Использование BN позволило достичь двух целей:

BN: эффект

Использование BN позволило достичь двух целей:

- Ускорить обучение до одинакового качества (вплоть до 15 раз)

BN: эффект

Использование BN позволило достичь двух целей:

- Ускорить обучение до одинакового качества (вплоть до 15 раз)
- Улучшить качество (на 2.6%)

BN: эффект

Использование BN позволило достичь двух целей:

- Ускорить обучение до одинакового качества (вплоть до 15 раз)
- Улучшить качество (на 2.6%)

	Model	Steps to 72.2%	Max accuracy
	Inception	$31.0 \cdot 10^6$	72.2%
	BN-Baseline	$13.3 \cdot 10^6$	72.7%
LR = LR x 5 →	*BN-x5*	$2.1 \cdot 10^6$	73.0%
LR = LR x 30 →	*BN-x30*	$2.7 \cdot 10^6$	74.8%

BN: эффект

Использование BN позволило достичь двух целей:

- Ускорить обучение до одинакового качества (вплоть до 15 раз)
- Улучшить качество (на 2.6%)

Model	Steps to 72.2%	Max accuracy
Inception	$31.0 \cdot 10^6$	72.2%
BN-Baseline	$13.3 \cdot 10^6$	72.7%
LR = LR x 5 → *BN-x5*	$2.1 \cdot 10^6$	73.0%
LR = LR x 30 → *BN-x30*	$2.7 \cdot 10^6$	74.8%

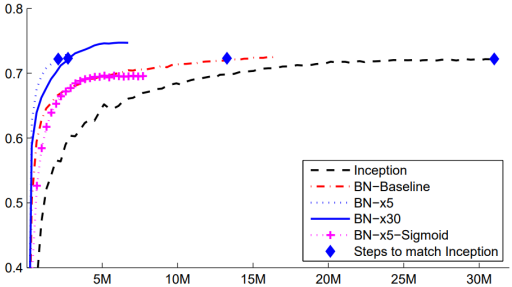

Другие виды нормализаций

- Нормализация по слою, а не по пакету[5] (layer normalization)

[5] Ba J. L., Kiros J. R., Hinton G. E. “Layer normalization”. 2016

[6] Ulyanov D., Vedaldi A., Lempitsky V. “Instance normalization: The missing ingredient for fast stylization”. 2016

[7] Wu Y., He K. “Group normalization”. 2018

Другие виды нормализаций

- Нормализация по слою, а не по пакету[5] (layer normalization)
- Нормализация по одной карте признаков[6] (instance normalization)

[5] Ba J. L., Kiros J. R., Hinton G. E. “Layer normalization”. 2016

[6] Ulyanov D., Vedaldi A., Lempitsky V. “Instance normalization: The missing ingredient for fast stylization”. 2016

[7] Wu Y., He K. “Group normalization”. 2018

Другие виды нормализаций

- Нормализация по слою, а не по пакету[5] (layer normalization)
- Нормализация по одной карте признаков[6] (instance normalization)
- Нормализация по части слоя[7] (group normalization)

[5] Ba J. L., Kiros J. R., Hinton G. E. “Layer normalization”. 2016

[6] Ulyanov D., Vedaldi A., Lempitsky V. “Instance normalization: The missing ingredient for fast stylization”. 2016

[7] Wu Y., He K. “Group normalization”. 2018

Другие виды нормализаций

- Нормализация по слою, а не по пакету[5] (layer normalization)
- Нормализация по одной карте признаков[6] (instance normalization)
- Нормализация по части слоя[7] (group normalization)

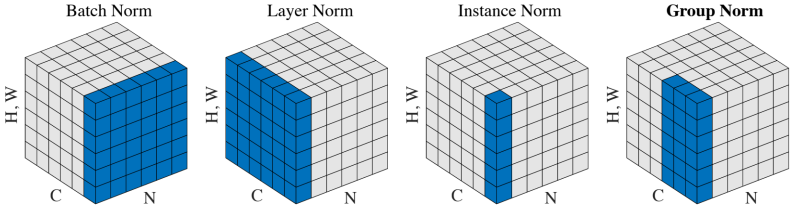

[5] Ba J. L., Kiros J. R., Hinton G. E. “Layer normalization”. 2016

[6] Ulyanov D., Vedaldi A., Lempitsky V. “Instance normalization: The missing ingredient for fast stylization”. 2016

[7] Wu Y., He K. “Group normalization”. 2018

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика по слою

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика по слою

- $\mu_B^t = \frac{1}{HWM} \sum_m \sum_{i,j} X_{ij}^{mt}$

LN: Нормализация по слою

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика по слою

- $\mu_B^t = \frac{1}{HWM} \sum_m \sum_{i,j} X_{ij}^{mt}$
- $\sigma_B^{2t} = \frac{1}{HWM} \sum_m \sum_{i,j} (X_{ij}^{mt} - \mu_B^t)^2$

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \ldots M$ — номер карты признаков,
  - $t = 1 \ldots T$ — номер внутри пакета.

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \ldots M$ — номер карты признаков,
  - $t = 1 \ldots T$ — номер внутри пакета.

Статистика по одной карте признаков

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика по одной карте признаков

- $\mu_B^{mt} = \frac{1}{HW} \sum_{i,j} X_{ij}^{mt}$

IN: Нормализация по одной карте признаков

- Предположим, что мы используем пакет размера T
- X_{ij}^{mt} — четырехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — номер карты признаков,
  - $t = 1 \dots T$ — номер внутри пакета.

Статистика по одной карте признаков

- $\mu_B^{mt} = \frac{1}{HW} \sum_{i,j} X_{ij}^{mt}$
- $\sigma_B^{2mt} = \frac{1}{HW} \sum_{i,j} (X_{ij}^{mt} - \mu_B^{mt})^2$

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где

[8] Qiao S. et al. “Weight standardization.” 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \ldots M$ — количество карт входного слоя,
  - $k = 1 \ldots K$ — количество карт выходного слоя.

[8] Qiao S. et al. "Weight standardization." 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \ldots M$ — количество карт входного слоя,
  - $k = 1 \ldots K$ — количество карт выходного слоя.

Стандартизация весов

[8] Qiao S. et al. "Weight standardization." 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — количество карт входного слоя,
  - $k = 1 \dots K$ — количество карт выходного слоя.

Стандартизация весов

- $\mu_W^k = \frac{1}{pqM} \sum_m \sum_{u,v} W_{uv}^{mk}$

[8] Qiao S. et al. "Weight standardization." 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — количество карт входного слоя,
  - $k = 1 \dots K$ — количество карт выходного слоя.

Стандартизация весов

- $\mu_W^k = \frac{1}{pqM} \sum_m \sum_{u,v} W_{uv}^{mk}$
- $\sigma_W^{2k} = \frac{1}{pqM} \sum_m \sum_{u,v} (W_{uv}^{mk} - \mu_W^k)^2$

[8] Qiao S. et al. "Weight standardization." 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — количество карт входного слоя,
  - $k = 1 \dots K$ — количество карт выходного слоя.

Стандартизация весов

- $\mu_W^k = \frac{1}{pqM} \sum_m \sum_{u,v} W_{uv}^{mk}$
- $\sigma_W^{2k} = \frac{1}{pqM} \sum_m \sum_{u,v} (W_{uv}^{mk} - \mu_W^k)^2$
- $\hat{W}_{uv}^{mk} = \frac{W_{uv}^{mk} - \mu_W^k}{\sqrt{\sigma_W^{2k} + \epsilon}}$

[8] Qiao S. et al. "Weight standardization." 2019

WS: стандартизация весов[8]

- W_{uv}^{mk} — четырехмерный тензор значений для некоторого фильтра, где
  - $1 \leq u \leq p, 1 \leq v \leq q$ — пространственные координаты (ширина и высота),
  - $m = 1 \dots M$ — количество карт входного слоя,
  - $k = 1 \dots K$ — количество карт выходного слоя.

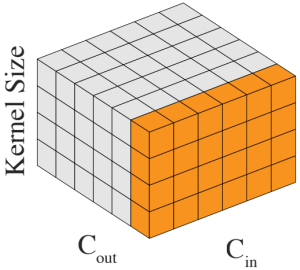

Стандартизация весов

- $\mu_W^k = \frac{1}{pqM} \sum_m \sum_{u,v} W_{uv}^{mk}$
- $\sigma_W^{2k} = \frac{1}{pqM} \sum_m \sum_{u,v} (W_{uv}^{mk} - \mu_W^k)^2$
- $\hat{W}_{uv}^{mk} = \frac{W_{uv}^{mk} - \mu_W^k}{\sqrt{\sigma_W^{2k} + \epsilon}}$

[8] Qiao S. et al. “Weight standardization.” 2019

Время для вопросов

Спасибо за внимание!