# Введение в искусственный интеллект. Современное компьютерное зрение

## Тема: Методы сжатия и ускорения нейронных сетей

Бабин Д.Н., Иванов И.Е.

кафедра Математической Теории Интеллектуальных Систем

31 марта 2026 г.

# План лекции

- Прунинг
- Квантование
- Дистилляция знаний и совместное обучение
- Ручное построение архитектуры нейронной сети
- Методы автоматического поиска архитектуры (NAS)

# Постановка задачи и приложения

- Ускорение модели
- Оптимизация модели под конкретное устройство
- Сжатие модели

# Прунинг

## Определение

Прунинг — это удаление связей в нейронных сетях

# Прунинг

## Определение

Прунинг — это удаление связей в нейронных сетях

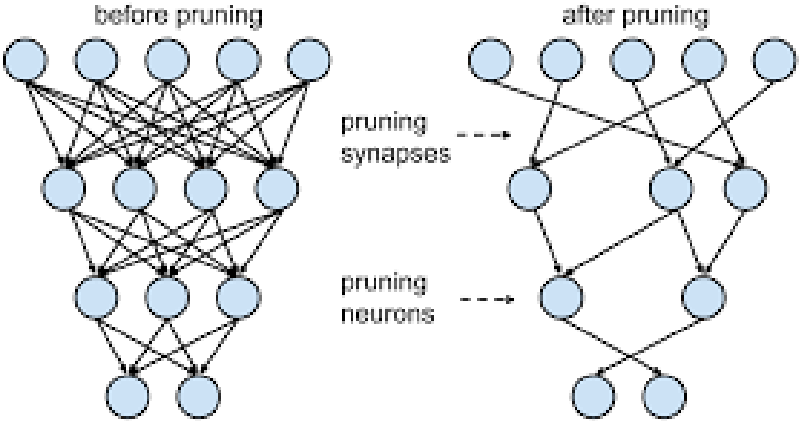

# Как выбирать удаляемые связи?

# Как выбирать удаляемые связи?

**Ответ**

Чтобы обнуление веса наименьшим образом влияло на качество, надо удалять наименее значимые связи, например, те, у которых наименьшие веса

# Проблема удаления связей

## Проблема

При удалении связей может существенно падать точность модели

# Проблема удаления связей

## Проблема

При удалении связей может существенно падать точность модели

## Возможные решения

- Для того, чтобы появлялось больше весов с маленьким весом, можно добавить $\ell_1/\ell_2$ - регуляризацию

# Проблема удаления связей

## Проблема

При удалении связей может существенно падать точность модели

## Возможные решения

- Для того, чтобы появлялось больше весов с маленьким весом, можно добавить $\ell_1/\ell_2$ - регуляризацию
- Производить дообучение модели после обнуления весов

# Типичная схема прунинга [1]

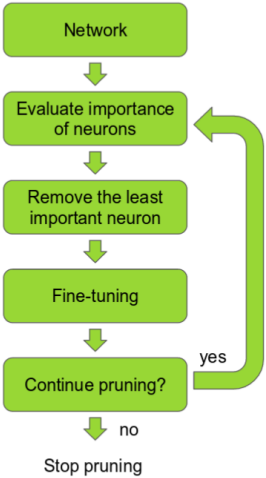


[1] https://arxiv.org/pdf/1611.06440.pdf

# Прунинг карт [2]

- С точки зрения вычислений выгоднее удалять не связи из графа, а нейроны целиком или карты или даже слои

[2] https://arxiv.org/pdf/1608.08710.pdf

# Прунинг карт [2]

- С точки зрения вычислений выгоднее удалять не связи из графа, а нейроны целиком или карты или даже слои

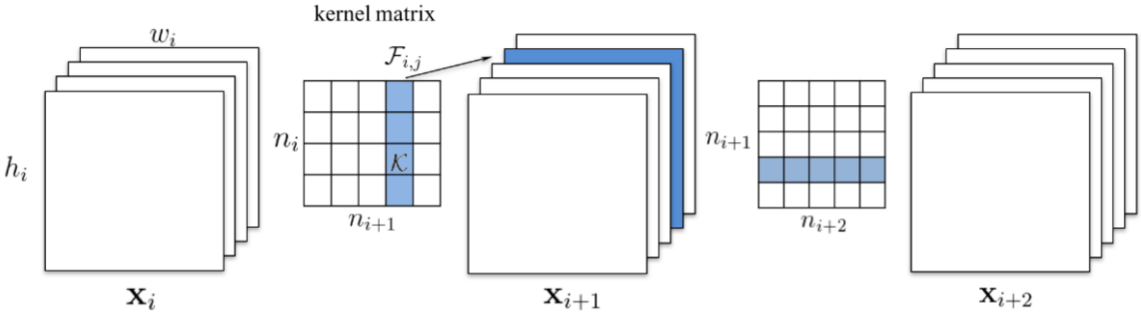


[2] https://arxiv.org/pdf/1608.08710.pdf

# Детали алгоритма

- Удаление карты происходит путем удаления весов с минимальной нормой весов (сумма квадратов или сумма абсолютных значений)
- Эта же норма добавляется к функции потерь с некоторым весом
- Удаление происходит постепенно и итеративно вместе с дообучением
- Критерий остановки либо достижение попрога по качесту модели, либо достижение необходимого вычислительного бюджета

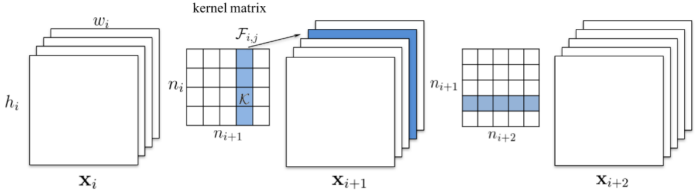

# Квантование

## Определение

Уменьшение битности параметров нейронной сети

# Квантование

## Определение

Уменьшение битности параметров нейронной сети

## Интуиция

- При уменьшении битности параметров, вычисления можно проводить быстрее
- Существенно уменьшается размер модели

## Методы квантования

- Обучение модели в полной точности, а потом округление до нужного количества бит

# Квантование

## Определение

Уменьшение битности параметров нейронной сети

## Интуиция

- При уменьшении битности параметров, вычисления можно проводить быстрее
- Существенно уменьшается размер модели

## Методы квантования

- Обучение модели в полной точности, а потом округление до нужного количества бит
- Как правило после округления идет дообучение

# Квантование

## Определение

Уменьшение битности параметров нейронной сети

## Интуиция

- При уменьшении битности параметров, вычисления можно проводить быстрее
- Существенно уменьшается размер модели

## Методы квантования

- Обучение модели в полной точности, а потом округление до нужного количества бит
- Как правило после округления идет дообучение
- Есть методы позволяющие обучать сразу квантизованные модели

# Бинарные нейронные сети

- Бинарные нейронные сети — экстремальный случай квантизации, когда веса имеют только два значения

# Бинарные нейронные сети

- Бинарные нейронные сети — экстремальный случай квантизации, когда веса имеют только два значения
- В таком виде обучение модели градиентном спуском затруднено, так как пространство дискретное

# Бинарные нейронные сети

- Бинарные нейронные сети — экстремальный случай квантизации, когда веса имеют только два значения
- В таком виде обучение модели градиентном спуском затруднено, так как пространство дискретное
- Довольно полезная задача для индустрии, которая ждем своего решения

# Дистилляция знаний [4]

## Идея

Передать знания от Учителя (большая нейронная сеть или ансамбль моделей) к Студенту (маленькая нейронная сеть)

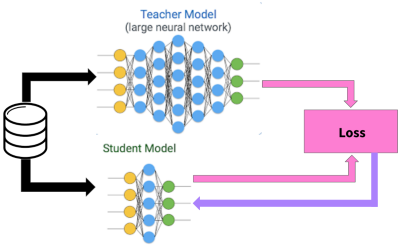


3

[3] https://towardsdatascience.com/knowledge-distillation-simplified-dd4973dbc764

[4] CristianBucila,RichCaruana,andAlexandruNiculescu-Mizil.ModelCompression.KDD,2006

# Дистилляция знаний: интуиция

## Допущение

Мы будем рассматривать **классификационную** нейронную сеть

## Вопрос

Почему использование учителя может работать лучше, чем просто обучение?

# Дистилляция знаний: интуиция

## Допущение

Мы будем рассматривать **классификационную** нейронную сеть

## Вопрос

Почему использование учителя может работать лучше, чем просто обучение?

## Ответ

- В задаче классификации разметка осуществляется путем выбора одного наиболее подходящего класса. Обученная нейронная сеть же выдаёт распределение по классам, которое содержит дополнительную информацию
- Можно расширить обучающий датасет, используя выход Учителя, как аннотацию

# Дистилляция знаний: функция потерь [5]

## Softmax с температурой

$$q_i = \frac{exp(\frac{z_i}{T})}{\sum_j exp(\frac{z_j}{T})}$$

[5] https://arxiv.org/abs/1503.02531

# Дистилляция знаний: функция потерь [5]

## Softmax с температурой

$$q_i = \frac{exp(\frac{z_i}{T})}{\sum_j exp(\frac{z_j}{T})}$$

## Свойства

- При $T = 1$ обычный Softmax
- При $T \to \infty$ вероятности будут всё больше выравниваться
- Где в промежутке станут доступны для обучения дополнительная информация из распределения (сам Хинтон называл это "dark knowledge")

[5] https://arxiv.org/abs/1503.02531

# Дистилляция знаний: функция потерь [5]

## Softmax с температурой

$$q_i = \frac{exp(\frac{z_i}{T})}{\sum_j exp(\frac{z_j}{T})}$$

## Свойства

- При $T = 1$ обычный Softmax
- При $T \to \infty$ вероятности будут всё больше выравниваться
- Где в промежутке станут доступны для обучения дополнительная информация из распределения (сам Хинтон называл это "dark knowledge")

$$\mathcal{L}(x; W) = \alpha * \mathcal{H}(y, \sigma(z_s; T = 1)) + \beta * \mathcal{H}(\sigma(z_t; T = \tau), \sigma(z_s, T = \tau))$$

[5] https://arxiv.org/abs/1503.02531

# Дистилляция знаний

$$\mathcal{L}(x;W) = \alpha * \mathcal{H}(y, \sigma(z_s; T=1)) + \beta * \mathcal{H}(\sigma(z_t; T=\tau), \sigma(z_s, T=\tau))$$

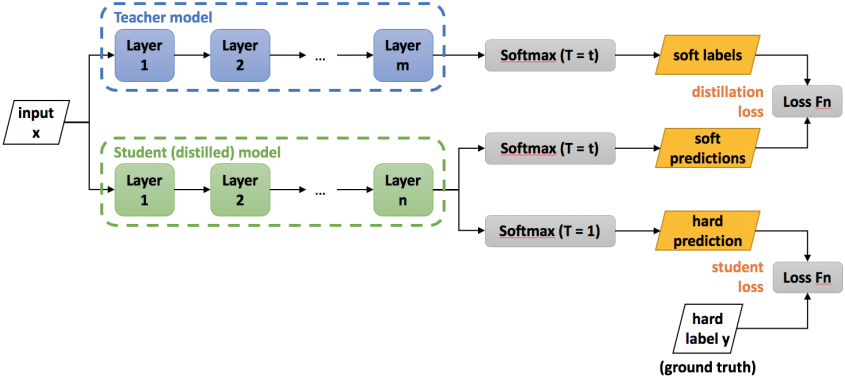

# Совместное обучение [6]

## Идея

Учиться вместе помогает достичь более высоких результатов

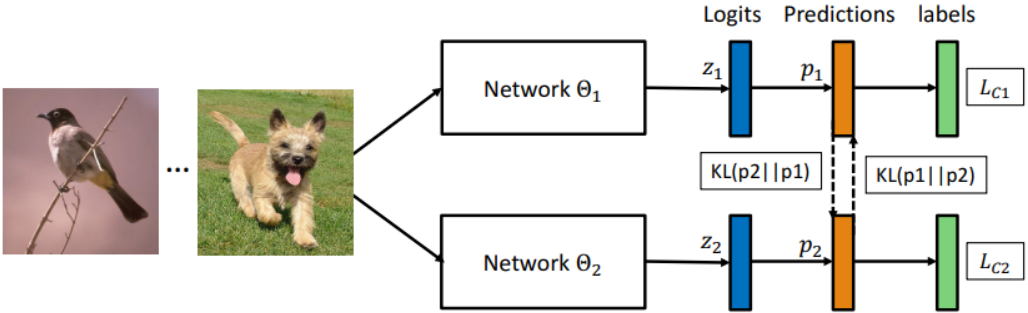


[6] https://arxiv.org/abs/1706.00384

# Эффективные архитектуры

- MobileNet
- ShuffleNet
- EfficientNet

# MobileNet [7]

## Идея

Замена свёрток $3 \times 3$ на depth-wise separable convolution

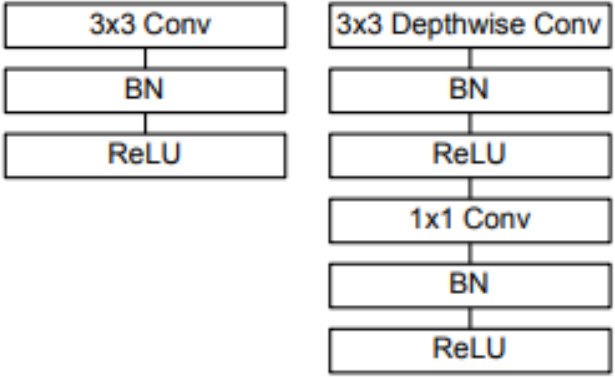


[7] https://arxiv.org/abs/1704.04861

# Архитектура MobileNet

Table 1. MobileNet Body Architecture

| Type / Stride | Filter Shape | Input Size |
|---|---|---|
| Conv / s2 | $3 \times 3 \times 3 \times 32$ | $224 \times 224 \times 3$ |
| Conv dw / s1 | $3 \times 3 \times 32$ dw | $112 \times 112 \times 32$ |
| Conv / s1 | $1 \times 1 \times 32 \times 64$ | $112 \times 112 \times 32$ |
| Conv dw / s2 | $3 \times 3 \times 64$ dw | $112 \times 112 \times 64$ |
| Conv / s1 | $1 \times 1 \times 64 \times 128$ | $56 \times 56 \times 64$ |
| Conv dw / s1 | $3 \times 3 \times 128$ dw | $56 \times 56 \times 128$ |
| Conv / s1 | $1 \times 1 \times 128 \times 128$ | $56 \times 56 \times 128$ |
| Conv dw / s2 | $3 \times 3 \times 128$ dw | $56 \times 56 \times 128$ |
| Conv / s1 | $1 \times 1 \times 128 \times 256$ | $28 \times 28 \times 128$ |
| Conv dw / s1 | $3 \times 3 \times 256$ dw | $28 \times 28 \times 256$ |
| Conv / s1 | $1 \times 1 \times 256 \times 256$ | $28 \times 28 \times 256$ |
| Conv dw / s2 | $3 \times 3 \times 256$ dw | $28 \times 28 \times 256$ |
| Conv / s1 | $1 \times 1 \times 256 \times 512$ | $14 \times 14 \times 256$ |
| $5\times$ Conv dw / s1 | $3 \times 3 \times 512$ dw | $14 \times 14 \times 512$ |
| Conv / s1 | $1 \times 1 \times 512 \times 512$ | $14 \times 14 \times 512$ |
| Conv dw / s2 | $3 \times 3 \times 512$ dw | $14 \times 14 \times 512$ |
| Conv / s1 | $1 \times 1 \times 512 \times 1024$ | $7 \times 7 \times 512$ |
| Conv dw / s2 | $3 \times 3 \times 1024$ dw | $7 \times 7 \times 1024$ |
| Conv / s1 | $1 \times 1 \times 1024 \times 1024$ | $7 \times 7 \times 1024$ |
| Avg Pool / s1 | Pool $7 \times 7$ | $7 \times 7 \times 1024$ |
| FC / s1 | $1024 \times 1000$ | $1 \times 1 \times 1024$ |

# Архитектура MobileNet

Table 1. MobileNet Body Architecture

| Type / Stride | Filter Shape | Input Size |
|---|---|---|
| Conv / s2 | $3 \times 3 \times 3 \times 32$ | $224 \times 224 \times 3$ |
| Conv dw / s1 | $3 \times 3 \times 32$ dw | $112 \times 112 \times 32$ |
| Conv / s1 | $1 \times 1 \times 32 \times 64$ | $112 \times 112 \times 32$ |
| Conv dw / s2 | $3 \times 3 \times 64$ dw | $112 \times 112 \times 64$ |
| Conv / s1 | $1 \times 1 \times 64 \times 128$ | $56 \times 56 \times 64$ |
| Conv dw / s1 | $3 \times 3 \times 128$ dw | $56 \times 56 \times 128$ |
| Conv / s1 | $1 \times 1 \times 128 \times 128$ | $56 \times 56 \times 128$ |
| Conv dw / s2 | $3 \times 3 \times 128$ dw | $56 \times 56 \times 128$ |
| Conv / s1 | $1 \times 1 \times 128 \times 256$ | $28 \times 28 \times 128$ |
| Conv dw / s1 | $3 \times 3 \times 256$ dw | $28 \times 28 \times 256$ |
| Conv / s1 | $1 \times 1 \times 256 \times 256$ | $28 \times 28 \times 256$ |
| Conv dw / s2 | $3 \times 3 \times 256$ dw | $28 \times 28 \times 256$ |
| Conv / s1 | $1 \times 1 \times 256 \times 512$ | $14 \times 14 \times 256$ |
| $5\times$ Conv dw / s1 | $3 \times 3 \times 512$ dw | $14 \times 14 \times 512$ |
| Conv / s1 | $1 \times 1 \times 512 \times 512$ | $14 \times 14 \times 512$ |
| Conv dw / s2 | $3 \times 3 \times 512$ dw | $14 \times 14 \times 512$ |
| Conv / s1 | $1 \times 1 \times 512 \times 1024$ | $7 \times 7 \times 512$ |
| Conv dw / s2 | $3 \times 3 \times 1024$ dw | $7 \times 7 \times 1024$ |
| Conv / s1 | $1 \times 1 \times 1024 \times 1024$ | $7 \times 7 \times 1024$ |
| Avg Pool / s1 | Pool $7 \times 7$ | $7 \times 7 \times 1024$ |
| FC / s1 | $1024 \times 1000$ | $1 \times 1 \times 1024$ |

Table 2. Resource Per Layer Type

| Type | Mult-Adds | Parameters |
|---|---|---|
| Conv $1 \times 1$ | 94.86% | 74.59% |
| Conv DW $3 \times 3$ | 3.06% | 1.06% |
| Conv $3 \times 3$ | 1.19% | 0.02% |
| Fully Connected | 0.18% | 24.33% |

# MobileNet: Результаты

Table 4. Depthwise Separable vs Full Convolution MobileNet

| Model | ImageNet Accuracy | Million Mult-Adds | Million Parameters |
|---|---|---|---|
| Conv MobileNet | 71.7% | 4866 | 29.3 |
| MobileNet | 70.6% | 569 | 4.2 |

# MobileNetV2: Новые блоки [8]

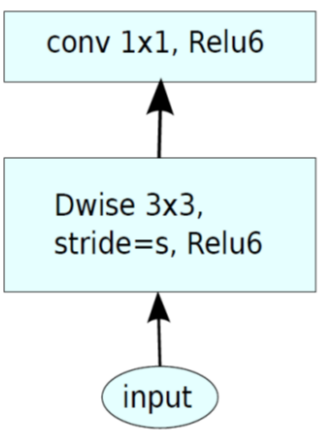


MobileNetV1

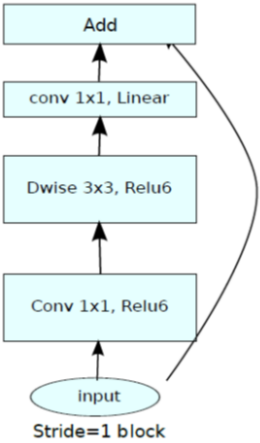


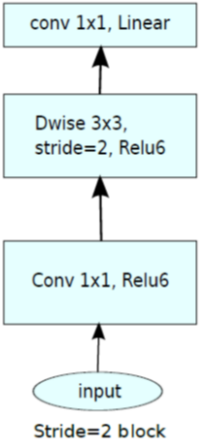


MobileNetV2

[8] https://arxiv.org/abs/1801.04381

# MobileNetV2: Архитектура

| Input | Operator | $t$ | $c$ | $n$ | $s$ |
|---|---|---|---|---|---|
| $224^2 \times 3$ | conv2d | - | 32 | 1 | 2 |
| $112^2 \times 32$ | bottleneck | 1 | 16 | 1 | 1 |
| $112^2 \times 16$ | bottleneck | 6 | 24 | 2 | 2 |
| $56^2 \times 24$ | bottleneck | 6 | 32 | 3 | 2 |
| $28^2 \times 32$ | bottleneck | 6 | 64 | 4 | 2 |
| $14^2 \times 64$ | bottleneck | 6 | 96 | 3 | 1 |
| $14^2 \times 96$ | bottleneck | 6 | 160 | 3 | 2 |
| $7^2 \times 160$ | bottleneck | 6 | 320 | 1 | 1 |
| $7^2 \times 320$ | conv2d 1x1 | - | 1280 | 1 | 1 |
| $7^2 \times 1280$ | avgpool 7x7 | - | - | 1 | - |
| $1 \times 1 \times 1280$ | conv2d 1x1 | - | k | - | |

# ShuffleNet [9]

## Идея

Использование групповой свёртки и операцию перемешивания (Shuffle)

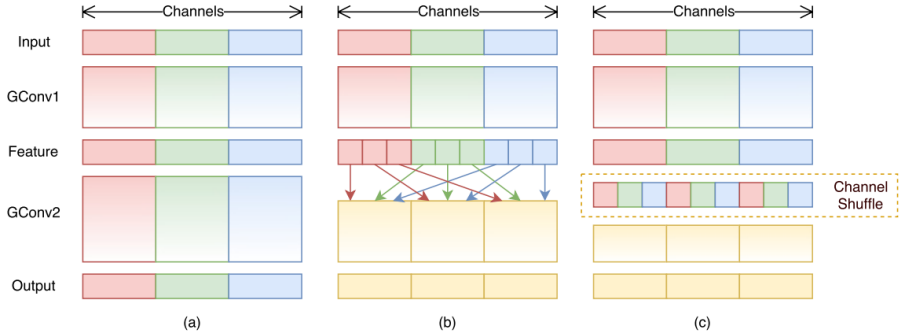


[9] https://arxiv.org/abs/1707.01083

# Блоки ShuffleNet

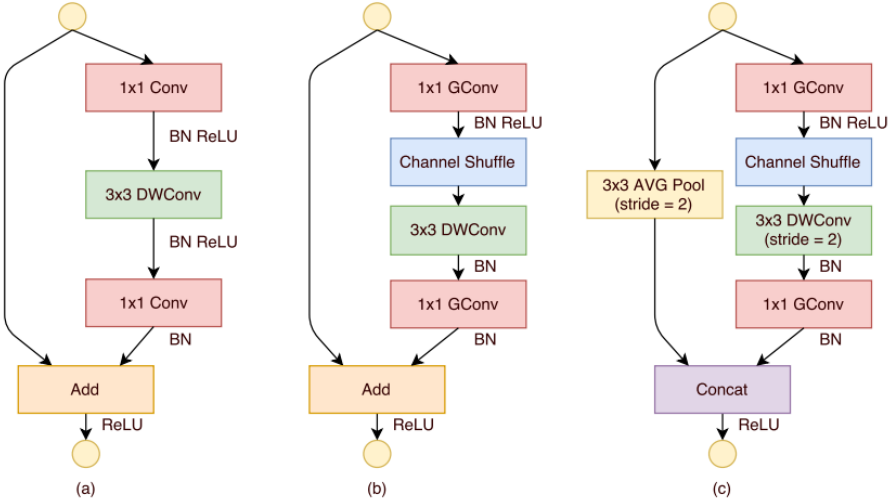

# Архитектура ShuffleNet

Table 1: ShuffleNet architecture

| Layer | Output size | KSize | Stride | Repeat | Output channels ($g$ groups) | | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | | | | $g = 1$ | $g = 2$ | $g = 3$ | $g = 4$ | $g = 8$ |
| Image | $224 \times 224$ | | | | 3 | 3 | 3 | 3 | 3 |
| Conv1 | $112 \times 112$ | $3 \times 3$ | 2 | 1 | 24 | 24 | 24 | 24 | 24 |
| MaxPool | $56 \times 56$ | $3 \times 3$ | 2 | | | | | | |
| Stage2[1] | $28 \times 28$ | | 2 | 1 | 144 | 200 | 240 | 272 | 384 |
| | $28 \times 28$ | | 1 | 3 | 144 | 200 | 240 | 272 | 384 |
| Stage3 | $14 \times 14$ | | 2 | 1 | 288 | 400 | 480 | 544 | 768 |
| | $14 \times 14$ | | 1 | 7 | 288 | 400 | 480 | 544 | 768 |
| Stage4 | $7 \times 7$ | | 2 | 1 | 576 | 800 | 960 | 1088 | 1536 |
| | $7 \times 7$ | | 1 | 3 | 576 | 800 | 960 | 1088 | 1536 |
| GlobalPool | $1 \times 1$ | $7 \times 7$ | | | | | | | |
| FC | | | | | 1000 | 1000 | 1000 | 1000 | 1000 |
| Complexity[2] | | | | | 143M | 140M | 137M | 133M | 137M |

# ShuffleNet: Результаты

Table 2: Classification error vs. number of groups $g$ (*smaller number represents better performance*)

| Model | Complexity (MFLOPs) | Classification error (%) | | | | |
|---|---|---|---|---|---|---|
| | | $g = 1$ | $g = 2$ | $g = 3$ | $g = 4$ | $g = 8$ |
| ShuffleNet 1× | 140 | 35.1 | 34.2 | **34.1** | 34.3 | 34.7 |
| ShuffleNet 0.5× | 38 | 46.1 | 45.1 | 44.4 | **43.7** | 43.8 |
| ShuffleNet 0.25× | 13 | 56.7 | 56.3 | 55.6 | 54.5 | **53.7** |
| ShuffleNet 0.5× (arch2) | 40 | 45.7 | 44.3 | 43.8 | 43.2 | **42.7** |
| ShuffleNet 0.25× (arch2) | 13 | 56.5 | 55.3 | 55.5 | 54.3 | **53.3** |

# ShuffleNet: Результаты

Table 2: Classification error vs. number of groups $g$ (*smaller number represents better performance*)

| Model | Complexity (MFLOPs) | Classification error (%) | | | | |
|---|---|---|---|---|---|---|
| | | $g = 1$ | $g = 2$ | $g = 3$ | $g = 4$ | $g = 8$ |
| ShuffleNet 1× | 140 | 35.1 | 34.2 | **34.1** | 34.3 | 34.7 |
| ShuffleNet 0.5× | 38 | 46.1 | 45.1 | 44.4 | **43.7** | 43.8 |
| ShuffleNet 0.25× | 13 | 56.7 | 56.3 | 55.6 | 54.5 | **53.7** |
| ShuffleNet 0.5× (arch2) | 40 | 45.7 | 44.3 | 43.8 | 43.2 | **42.7** |
| ShuffleNet 0.25× (arch2) | 13 | 56.5 | 55.3 | 55.5 | 54.3 | **53.3** |

| Model | Cls err. (%, no shuffle) | Cls err. (%, shuffle) | Δ err. (%) |
|---|---|---|---|
| ShuffleNet 1x ($g = 3$) | 34.5 | **32.6** | 1.9 |
| ShuffleNet 1x ($g = 8$) | 37.6 | **32.4** | 5.2 |
| ShuffleNet 0.5x ($g = 3$) | 45.7 | **43.2** | 2.5 |
| ShuffleNet 0.5x ($g = 8$) | 48.1 | **42.3** | 5.8 |
| ShuffleNet 0.25x ($g = 3$) | 56.3 | **55.0** | 1.3 |
| ShuffleNet 0.25x ($g = 8$) | 56.5 | **52.7** | 3.8 |

# ShuffleNet: Сравнение с другими моделями

Table 6: Complexity comparison

| Model | Cls err. (%) | Complexity (MFLOPs) |
|---|---|---|
| VGG-16 [27] | 28.5 | 15300 |
| ShuffleNet $2\times$ ($g = 3$) | 29.1 | **524** |
| PVANET [18] (*our impl.*) | 35.3 | 557 |
| ShuffleNet $1\times$ ($g = 3$) | 34.1 | **140** |
| AlexNet [19] | 42.8 | 720 |
| SqueezeNet [13] | 42.5 | 833 |
| ShuffleNet $0.5\times$ (arch2, $g = 8$) | 42.7 | **40** |

# ShuffleNet: Сравнение с другими моделями

Table 5: ShuffleNet vs. MobileNet [12] on ImageNet Classification

| Model | Complexity (MFLOPs) | Cls err. (%) | $\Delta$ err. (%) |
|---|---|---|---|
| 1.0 MobileNet-224 | 569 | 29.4 | - |
| ShuffleNet 2× ($g = 3$) | 524 | **29.1** | 0.3 |
| 0.75 MobileNet-224 | 325 | 31.6 | - |
| ShuffleNet 1.5× ($g = 3$) | 292 | **31.0** | 0.6 |
| 0.5 MobileNet-224 | 149 | 36.3 | - |
| ShuffleNet 1× ($g = 3$) | 140 | **34.1** | 2.2 |
| 0.25 MobileNet-224 | 41 | 49.4 | - |
| ShuffleNet 0.5× (arch2, $g = 8$) | 40 | **42.7** | 6.7 |
| ShuffleNet 0.5× (shallow, $g = 3$) | 40 | 45.2 | 4.2 |

# Сравнение моделей

| Network | Top 1 | Params | MAdds | CPU |
|---|---|---|---|---|
| MobileNetV1 | 70.6 | 4.2M | 575M | 113ms |
| ShuffleNet (1.5) | 71.5 | **3.4M** | 292M | - |
| ShuffleNet (x2) | 73.7 | 5.4M | 524M | - |
| NasNet-A | 74.0 | 5.3M | 564M | 183ms |
| MobileNetV2 | **72.0** | **3.4M** | **300M** | **75ms** |
| MobileNetV2 (1.4) | **74.7** | 6.9M | 585M | **143ms** |

# Этапы развития искусственного интеллекта

## Поколение 1: Старый добрый ИИ

- Конструирование алгоритмов под конкретные задачи
- Отсутствие обучения

# Этапы развития искусственного интеллекта

## Поколение 1: Старый добрый ИИ

- Конструирование алгоритмов под конкретные задачи
- Отсутствие обучения

## Поколение 2: Машинное обучение

- Конструирование признаков
- Обучение модели на готовых признаках

# Этапы развития искусственного интеллекта

## Поколение 3: Глубокое обучение

- Обучаемые признаки
- Обучаемые алгоритмы
- Гиперпараметры подбираются вручную

# Этапы развития искусственного интеллекта

## Поколение 3: Глубокое обучение

- Обучаемые признаки
- Обучаемые алгоритмы
- Гиперпараметры подбираются вручную

## Поколение 4: Метаобучение

- Никакой ручной работы
- Всё обучаемое

# NAS: Автоматический поиск архитектур

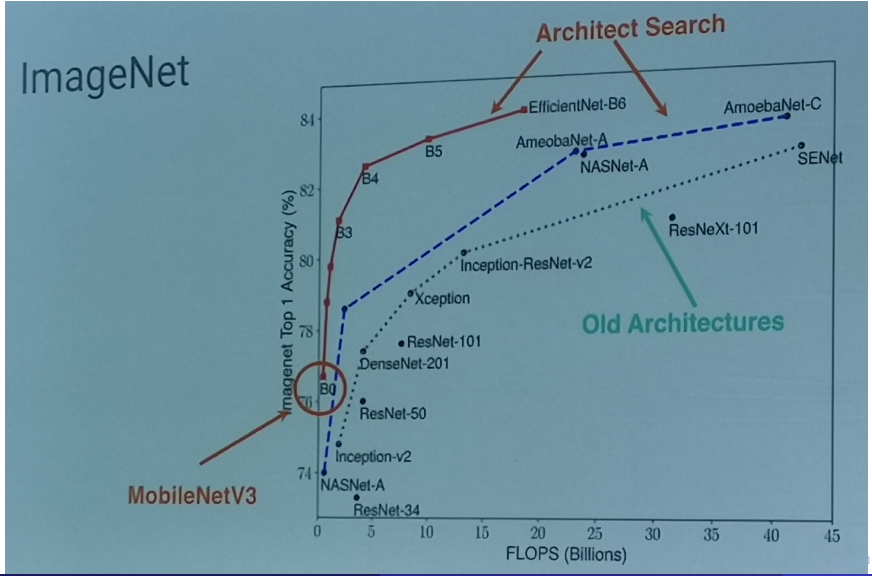

# NAS: Схема [10]

[10] https://towardsdatascience.com/neural-architecture-search-nas-the-future-of-deep-learning-c99356351136

# NAS

- Текущие лучшие решения имеют массу ограничений

# NAS

- Текущие лучшие решения имеют массу ограничений
- Большинство решений для задачи классификации

# NAS

- Текущие лучшие решения имеют массу ограничений
- Большинство решений для задачи классификации
- Увеличение качества или достигаемое ускорение не всегда существенно лучше решений, придуманных человеком

# NAS

- Текущие лучшие решения имеют массу ограничений
- Большинство решений для задачи классификации
- Увеличение качества или достигаемое ускорение не всегда существенно лучше решений, придуманных человеком
- Пока NAS не в состоянии полностью решить задачу и заменить исследователя/инженера

# EfficientNet [11]

## Идея

- Автоматический поиск сравнительно небольшой модели
- Эффективное масштабирование модели

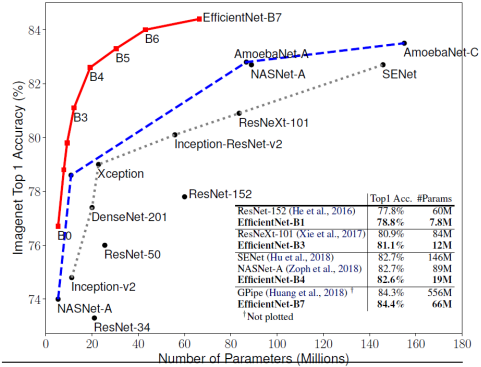


| | Top1 Acc. | #Params |
|---|---|---|
| ResNet-152 (He et al., 2016) | 77.8% | 60M |
| **EfficientNet-B1** | **78.8%** | **7.8M** |
| ResNeXt-101 (Xie et al., 2017) | 80.9% | 84M |
| **EfficientNet-B3** | **81.1%** | **12M** |
| SENet (Hu et al., 2018) | 82.7% | 146M |
| NASNet-A (Zoph et al., 2018) | 82.7% | 89M |
| **EfficientNet-B4** | **82.6%** | **19M** |
| GPipe (Huang et al., 2018) † | 84.3% | 556M |
| **EfficientNet-B7** | **84.4%** | **66M** |

† Not plotted

[11] https://arxiv.org/abs/1905.11946

# EfficientNet: Масштабирование модели

**EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks**

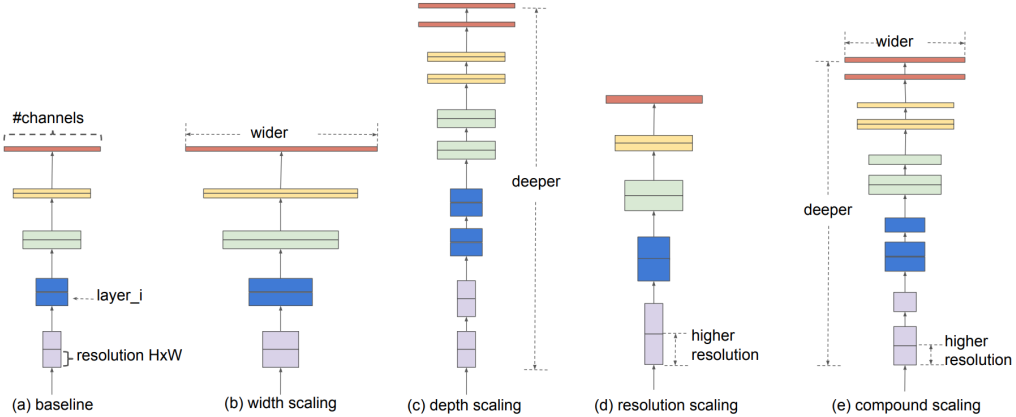

# EfficientNet: Масштабирование модели

## Масштабирование

Чем больше модель, тем меньше помагает масштабирование

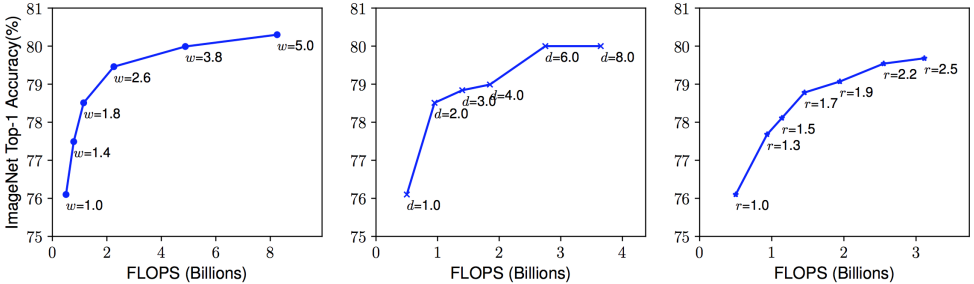

# EfficientNet: Масштабирование модели

$$
\begin{aligned}
\text{depth: } & d = \alpha^{\phi} \\
\text{width: } & w = \beta^{\phi} \\
\text{resolution: } & r = \gamma^{\phi} \\
\text{s.t. } & \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \\
& \alpha \geq 1, \beta \geq 1, \gamma \geq 1
\end{aligned}
$$

# EfficientNet: Масштабирование модели

$$
\begin{aligned}
\text{depth: } & d = \alpha^{\phi} \\
\text{width: } & w = \beta^{\phi} \\
\text{resolution: } & r = \gamma^{\phi} \\
\text{s.t. } & \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \\
& \alpha \geq 1, \beta \geq 1, \gamma \geq 1
\end{aligned}
$$

## Шаг 1

Для $\phi = 1.0$ параметры подбираются перебором по сетке:
$\alpha = 1.2,\ \beta = 1.1\ \gamma = 1.15$

# EfficientNet: Масштабирование модели

$$\text{depth: } d = \alpha^\phi$$
$$\text{width: } w = \beta^\phi$$
$$\text{resolution: } r = \gamma^\phi$$
$$\text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$$
$$\alpha \geq 1, \beta \geq 1, \gamma \geq 1$$

## Шаг 1

Для $\phi = 1.0$ параметры подбираются перебором по сетке:
$\alpha = 1.2,\ \beta = 1.1\ \gamma = 1.15$

## Шаг 2

При фиксированных $\alpha = 1.2,\ \beta = 1.1\ \gamma = 1.15$, меняя $\phi$, получаем большие модели

# EfficientNet: Результаты

| Model | Top-1 Acc. | Top-5 Acc. | #Params | Ratio-to-EfficientNet | #FLOPS | Ratio-to-EfficientNet |
|---|---|---|---|---|---|---|
| **EfficientNet-B0** | **76.3%** | **93.2%** | **5.3M** | **1x** | **0.39B** | **1x** |
| ResNet-50 (He et al., 2016) | 76.0% | 93.0% | 26M | 4.9x | 4.1B | 11x |
| DenseNet-169 (Huang et al., 2017) | 76.2% | 93.2% | 14M | 2.6x | 3.5B | 8.9x |
| **EfficientNet-B1** | **78.8%** | **94.4%** | **7.8M** | **1x** | **0.70B** | **1x** |
| ResNet-152 (He et al., 2016) | 77.8% | 93.8% | 60M | 7.6x | 11B | 16x |
| DenseNet-264 (Huang et al., 2017) | 77.9% | 93.9% | 34M | 4.3x | 6.0B | 8.6x |
| Inception-v3 (Szegedy et al., 2016) | 78.8% | 94.4% | 24M | 3.0x | 5.7B | 8.1x |
| Xception (Chollet, 2017) | 79.0% | 94.5% | 23M | 3.0x | 8.4B | 12x |
| **EfficientNet-B2** | **79.8%** | **94.9%** | **9.2M** | **1x** | **1.0B** | **1x** |
| Inception-v4 (Szegedy et al., 2017) | 80.0% | 95.0% | 48M | 5.2x | 13B | 13x |
| Inception-resnet-v2 (Szegedy et al., 2017) | 80.1% | 95.1% | 56M | 6.1x | 13B | 13x |
| **EfficientNet-B3** | **81.1%** | **95.5%** | **12M** | **1x** | **1.8B** | **1x** |
| ResNeXt-101 (Xie et al., 2017) | 80.9% | 95.6% | 84M | 7.0x | 32B | 18x |
| PolyNet (Zhang et al., 2017) | 81.3% | 95.8% | 92M | 7.7x | 35B | 19x |
| **EfficientNet-B4** | **82.6%** | **96.3%** | **19M** | **1x** | **4.2B** | **1x** |
| SENet (Hu et al., 2018) | 82.7% | 96.2% | 146M | 7.7x | 42B | 10x |
| NASNet-A (Zoph et al., 2018) | 82.7% | 96.2% | 89M | 4.7x | 24B | 5.7x |
| AmoebaNet-A (Real et al., 2019) | 82.8% | 96.1% | 87M | 4.6x | 23B | 5.5x |
| PNASNet (Liu et al., 2018) | 82.9% | 96.2% | 86M | 4.5x | 23B | 6.0x |
| **EfficientNet-B5** | **83.3%** | **96.7%** | **30M** | **1x** | **9.9B** | **1x** |
| AmoebaNet-C (Cubuk et al., 2019) | 83.5% | 96.5% | 155M | 5.2x | 41B | 4.1x |
| **EfficientNet-B6** | **84.0%** | **96.9%** | **43M** | **1x** | **19B** | **1x** |
| **EfficientNet-B7** | **84.4%** | **97.1%** | **66M** | **1x** | **37B** | **1x** |
| GPipe (Huang et al., 2018) | 84.3% | 97.0% | 557M | 8.4x | - | - |

We omit ensemble and multi-crop models (Hu et al., 2018), or models pretrained on 3.5B Instagram images (Mahajan et al., 2018).

# EfficientNet: Результаты

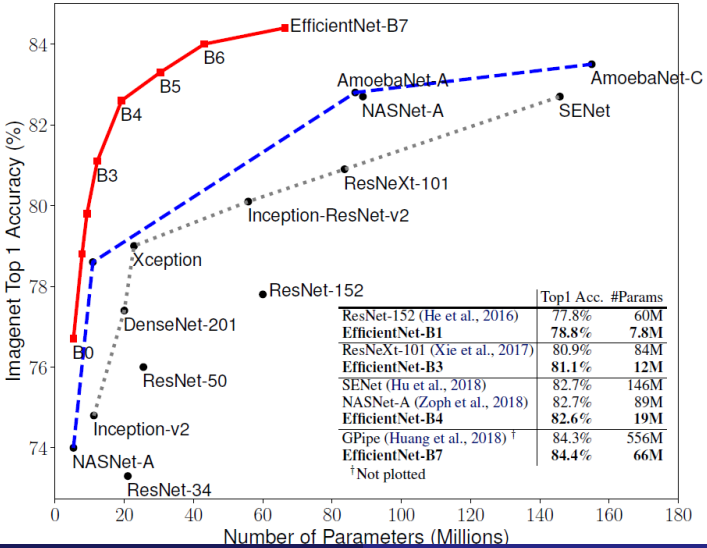


| | Top1 Acc. | #Params |
|---|---|---|
| ResNet-152 (He et al., 2016) | 77.8% | 60M |
| **EfficientNet-B1** | **78.8%** | **7.8M** |
| ResNeXt-101 (Xie et al., 2017) | 80.9% | 84M |
| **EfficientNet-B3** | **81.1%** | **12M** |
| SENet (Hu et al., 2018) | 82.7% | 146M |
| NASNet-A (Zoph et al., 2018) | 82.7% | 89M |
| **EfficientNet-B4** | **82.6%** | **19M** |
| GPipe (Huang et al., 2018) † | 84.3% | 556M |
| **EfficientNet-B7** | **84.4%** | **66M** |

† Not plotted

# Заключение

- Ускорение моделей и поиск более эффективных архитектур — тренд современного компьютерного зрения

# Заключение

- Ускорение моделей и поиск более эффективных архитектур — тренд современного компьютерного зрения
- Очень часто для ускорения моделей используют сразу несколько способов

# Заключение

- Ускорение моделей и поиск более эффективных архитектур — тренд современного компьютерного зрения
- Очень часто для ускорения моделей используют сразу несколько способов
- Эпоха глубокого обучения подходит к концу, NAS открывает новую эпоху в искусственном интеллекте

# Заключение

- Ускорение моделей и поиск более эффективных архитектур — тренд современного компьютерного зрения
- Очень часто для ускорения моделей используют сразу несколько способов
- Эпоха глубокого обучения подходит к концу, NAS открывает новую эпоху в искусственном интеллекте
- Учите математику, чтобы NAS не лишил вас работы

Спасибо за внимание!